

Сопоставление деклараций и регулирующих нормативно-правовых актов (НПА)

Data Scientist Тестовое задание

Ранжирование регулирующих НПА по тексту таможенной декларации

Задача

Для каждой таможенной декларации верните десять наиболее подходящих регулирующих НПА в порядке убывания релевантности. Выбор метода остаётся за вами. В README.md опишите принятый подход, рассмотренные альтернативы, допущения и основные компромиссы.

Если какое-либо условие не определено, сделайте разумное допущение и явно зафиксируйте его.

Данные

В комплекте используются следующие файлы:

declarations.jsonl

regulations.jsonl

151 декларация: служебные поля и описание товара. Правильная регуляция отсутствует.

562 регулирующих НПА: regulation_id, decree_number и текст НПА.

Запуск и результат

Среда подготавливается заранее: до запуска разрешается однократно скачать зависимости и необходимые модели. Эти действия не входят в лимит запуска. Разрешается использование локальной GPU и моделей размером не более 8 миллиардов параметров. После получения модели должны использоваться только из локально сохранённых файлов. Само решение запускается локально на CPU и/или GPU из корня проекта; любые сетевые запросы во время выполнения запрещены:

```
python run.py --out ./out
```

Лимит запуска — 30 минут и 8 ГБ оперативной памяти; видеопамять локальной GPU в этот лимит не входит. Все необходимые во время запуска зависимости, модели и другие файлы должны быть зафиксированы или поставляться воспроизводимо.

Обязательный файл out/predictions.csv: колонки declaration_id, rank, regulation_id, score. Для каждой декларации должно быть ровно 10 уникальных регуляций с рангами 1-10. score — конечное число; большее значение означает более высокую релевантность.

Оценка

Решение оценивается организаторами по закрытым правильным соответствиям деклараций и регулирующих НПА. Учитываются качество ранжирования, корректность формата, воспроизводимость, обоснованность решений и анализ ошибок.

Формат должен быть корректен для 100% деклараций. Отсутствующие строки, неизвестные ID, повторные регуляции и повторные ранги считаются ошибкой формата.

Что сдать

- исходный код и README.md с установкой, командами запуска, описанием подхода и зафиксированными версиями;
- полученный out/predictions.csv;
- краткое описание сложностей при анализе, влияющих на качество ранжирования, и способов их учёта в решении;
- воспроизводимое решение без сетевых запросов во время оценки.

Оцениваются качество поиска, обоснованность решений, воспроизводимость, анализ ошибок и понимание собственного подхода.